PRIRODOSLOVNO-MATEMATIČKI FAKULTET
SVEUČILIŠTE U SPLITU

Lovro Maglica

INFOTMATIČKI PROJEKT IZ BAZA PODATAKA: ODBOJKAŠKA LIGA

Seminarski rad

Studij:	Preddiplomski studij
Studijska grupa:	Informatika
Predmet:	IPBP
Ak. god.:	2025/2026.

Split, 2026.

Contents

1. Uvod....3
1.1. Opis projekta....3
2. Entiteti....4
2.1. Igrač....4
2.2. Nastup....4
2.3. Igrač_Klub....4
2.4. Klub....4
2.5. Trener_Klub....4
2.6. Trener....5
2.7. Utakmica....5
2.8. Dvorana....5
2.9. Sudac....5
2.10. Pošta....5
2.11. Županija....5
3. Relacije....6
3.1. Jedan na jedan....6
3.2. Jedan na više....6
3.3. Više na više....6
4. Modeli podataka....8
4.1. Konceptualni model....8
4.2. Logički Model....9
4.3. Relacijski Model....11
4.4. Generacija DDL-a....13
5. Izrada baze u SQL developeru....16
5.1. Izrada korisnika i dodjela prava....16
5.2. Izrada veze na novog korisnika....17
5.3. Izvršavanje DDL-a....18
6. Upiti....19
6.1. Insert....19
6.2. Update....20
6.3. Delete....21
6.4. Select....21
7. Zadaci....22

1. Uvod

1.1. Opis projekta

Ova baza podataka osmišljena je u svrhu praćenja rezultata i statistike odbojkaške lige. Cilj je klubovima, igračima i navijačima omogućiti brz i efikasan pristup rezultatima svih utakmica u sezoni. Prikazujemo gdje i kada se igraju određene utakmice tko igra na toj utakmici te sudce koji sude utakmicu. Također prikazujemo sastave ekipa koji igrač igra za koji klub, trenere koji vode klubove i sve detalje potrebne za praćenje statistike. Statistiku pratimo iz utakmice u utakmicu pa je moguće odrediti najboljeg igrača odnosno MVP-a (engl. Most Valuable Player) te utakmice, odrediti koliko je koja ekipa griješila, koliko je bilo izravnih poena iz svih elemenata igre (napad, blok i servis). Pratimo još i prijem igrača odnosno dodavanje servisa pratimo dobra dodavanja, neutralna dodavanja i loša dodavanja iz toga izvlačimo i postotak prijema servisa za pojedinog igrača te i za sveukupnu ekipu.

2. Entiteti

Entitet predstavlja objekt ili pojam o kojem želimo prikupljati i pohranjivati podatke unutar baze. Svaki entitet opisuje određenu kategoriju informacija koja je relevantna za funkcionalnost sustava, a njegove pojedinačne instance mogu se međusobno razlikovati i jednoznačno identificirati.
U procesu modeliranja baze podataka, entiteti se mogu zamisliti kao tablice, dok njihovi atributi predstavljaju stupce koji opisuju svojstva tih entiteta. Ključno je pravilno identificirati koje informacije trebamo pratiti te uspostaviti logičke veze između entiteta kako bi baza bila funkcionalna i zadovoljavala potrebe sustava.
Za potrebe ove baze podataka definirani su sljedeći entiteti:

1. Igrač
2. Klub
3. Trener
4. Utakmica
5. Sudac
6. Dvorana
7. Pošta
8. Županija
9. Nastup
10. Igrač_Klub
11. Trener_Klub

2.1. Igrač

Ovaj entitet sadrži osnovne podatke o igraču: identifikacijski broj igrača, ime, prezime i datum rođenja.

2.2. Nastup

Entitet koji evidentira nastup igrača na utakmici. Sadrži informacije o identifikacijskom broju nastupa, utakmici na kojoj se nastup odvio, broju setova, broju poena, broju blokova dobrih, loših i neutralnih, broju servis poena, broju as servisa, broju grešaka u servisu i broju dobro primljenih servisa, broju prijema dobrih, loših i grešaka.

2.3. Igrač_Klub

Ovaj entitet povezuje igrača s klubom za koji igra. Sadrži podatke o identifikacijskom broju igrača, identifikacijskom broju kluba, broju dresa i poziciji koju igra u timu.

2.4. Klub

Entitet koji sadrži osnovne informacije o klubu: ime kluba, identifikacijski broj kluba, kontakt podatke, boju domaceg dresa, boju gostujuceg dresa i adresa klubske uprave.

2.5. Trener_Klub

Ovaj entitet povezuje trenera s klubom u kojem radi. Sadrži identifikacijski broj trenera, identifikacijski broj kluba.

2.6. Trener

Entitet koji sadrži osnovne podatke o treneru: identifikacijski broj trenera, ime, prezime, datum rođenja.

2.7. Utakmica

Jedan od ključnih entiteta koji evidentira podatke o utakmici. Sadrži identifikacijski broj utakmice, identifikacijski broj domaće ekipe, identifikacijski broj gostujuće ekipe, identifikacijske brojeve glavnog i pomoćnog sudca, datum održavanja utakmice, dvorana u kojoj se igra utakmica, broj gledatelja i detaljne rezultate po setovima.

2.8. Dvorana

Entitet koji sadrži informacije o dvorani: identifikacijski broj dvorane, adresu, kapacitet i naziv.

2.9. Sudac

Entitet koji sadrži podatke o sucu: identifikacijski broj suca, ime, prezime, datum rođenja.

2.10. Pošta

Sadrži informacije o poštanskim brojevima i pripadajućim mjestima.

2.11. Županija

Entitet koji evidentira podatke o nazivu županije i pripadajućim kratica.

3. Relacije

Relacije su ključne za definiranje veza između entiteta u bazi podataka. One su bitne jer omogućuju bazi podataka da ima funkcionalnost i svrhu. Ove veze pružaju strukturu koja omogućuje sustavu da razumije složene odnose između entiteta, što olakšava pravilno organiziranje i manipulaciju podacima.
Postoje 3 vrste relacija:

1. Jedan na jedan (One-to-one) 1:1
2. Jedan na više (One-to-many) 1:n
3. Više na više (Many-to-many) m:n

3.1. Jedan na jedan

Relacija jedan prema jedan u bazi podataka omogućuje jednoznačnu vezu između entiteta u dvije tablice, gdje svaki entitet u jednoj tablici ima samo jedan povezani entitet u drugoj tablici i obrnuto.
U ovome modelu nemamo primjer takve veze.

3.2. Jedan na više

U relaciji jedan prema više jedan entitet iz jedne tablice može biti povezan s više entiteta iz druge tablice, ali svaki entitet iz druge tablice može biti povezan samo s jednim entitetom iz prve tablice.
U modelu odbojkaške lige vidimo primjere te veze kod **Dvorana → Utakmica**, ovom vezom smo rekli da se jedna utakmica može održati u jednoj dvorani, ali da se u jednoj dvorani može održati više utakmica
Pored nje imamo tu i još neke jedan na više veze:
Klub → Utakmica (jedan klub – više utakmica, jedna utakmica – jedan klub) i ovu vezu ponavljamo dva put jer igaju dva kluba
Sudac → Utakmica (jedan sudac – više utakmica, jedna utakmica – jedan sudac) i ovu vezu isto ponavljamo dva puta jer imamo glavnog i sporednog sudca
Pošta → Dvorana (jedna pošta – više dvorana, jedna dvorana – jedna pošta)
Pošta → Klub (jedna pošta – više klubova, jedan klub – jedna pošta)
Županija → Pošta (jedna županija – više pošta, jedna pošta – jedna županija)
Dvorana → Utakmica (u jednoj dvorani –se igra više utakmica, jedna utakmica – jedna dvorana)

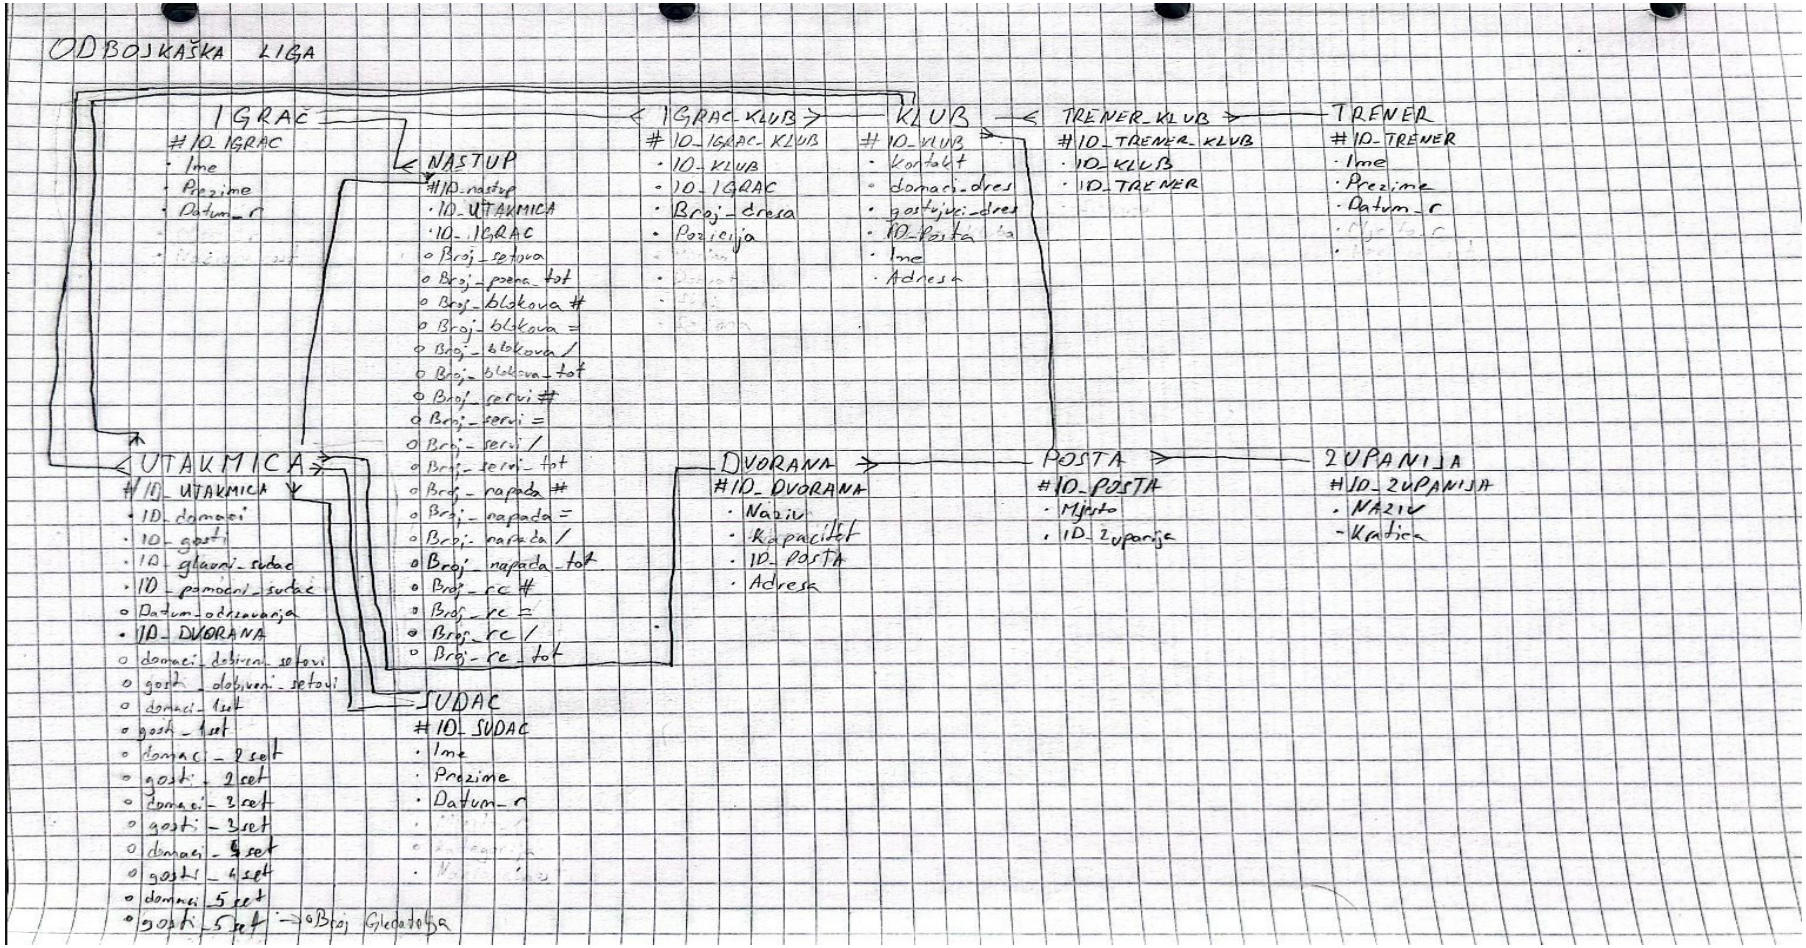
3.3. Više na više

Relacija više na više implicira da više entiteta iz jedne tablice može biti povezano s više entiteta iz druge tablice. Drugim riječima, jedan entitet iz prve tablice može biti povezan s više entiteta iz druge tablice, i obrnuto.
Ovaj „problem" se rješava preko treće tablice koja služi za povezivanje informacija između dvije tablice.
Imamo vezu **Igrač ↔ Klub**, želimo pratiti za koje klubove je igrač igrao kroz svoju karijeru. Više nije slučaj kao u prethodnim zato jer jedan igrač može igrati za više klubova (kroz vrijeme), a isto tako jedan klub ima više igrača.
Uvodimo treću tablicu nazvanu **Igrač_klub** kako bismo olakšali praćenje igrača i klubova za koje su igrali. Ova tablica će sadržavati ID-ove igrača i kluba iz originalnih tablica,ne koristimo kompozitni primarni ključ jer igrač može napustiti klub i vratiti se par godina nakon

i tada to nebi mogli napisati ako imamo kompozitni primarni ključ. Osim toga, sadrži dodatne informacije kao što su broj dresa i pozicija koje se mogu mjenjati iz sezone u sezonu.
Isto tako vrijedi za vezu **Trener ↔ Klub**, uvodimo novi entitet **Trener_klub** i u njoj bilježimo sve potrebne podatke o tome koji trener radi u kojem klubu.
Pored njih imamo i **Igrac ↔ Utakmica** uvodimo novi entitet **Nastup** gdje pratimo statistiku igraca u odredenoj utakmici.

4. Modeli podataka

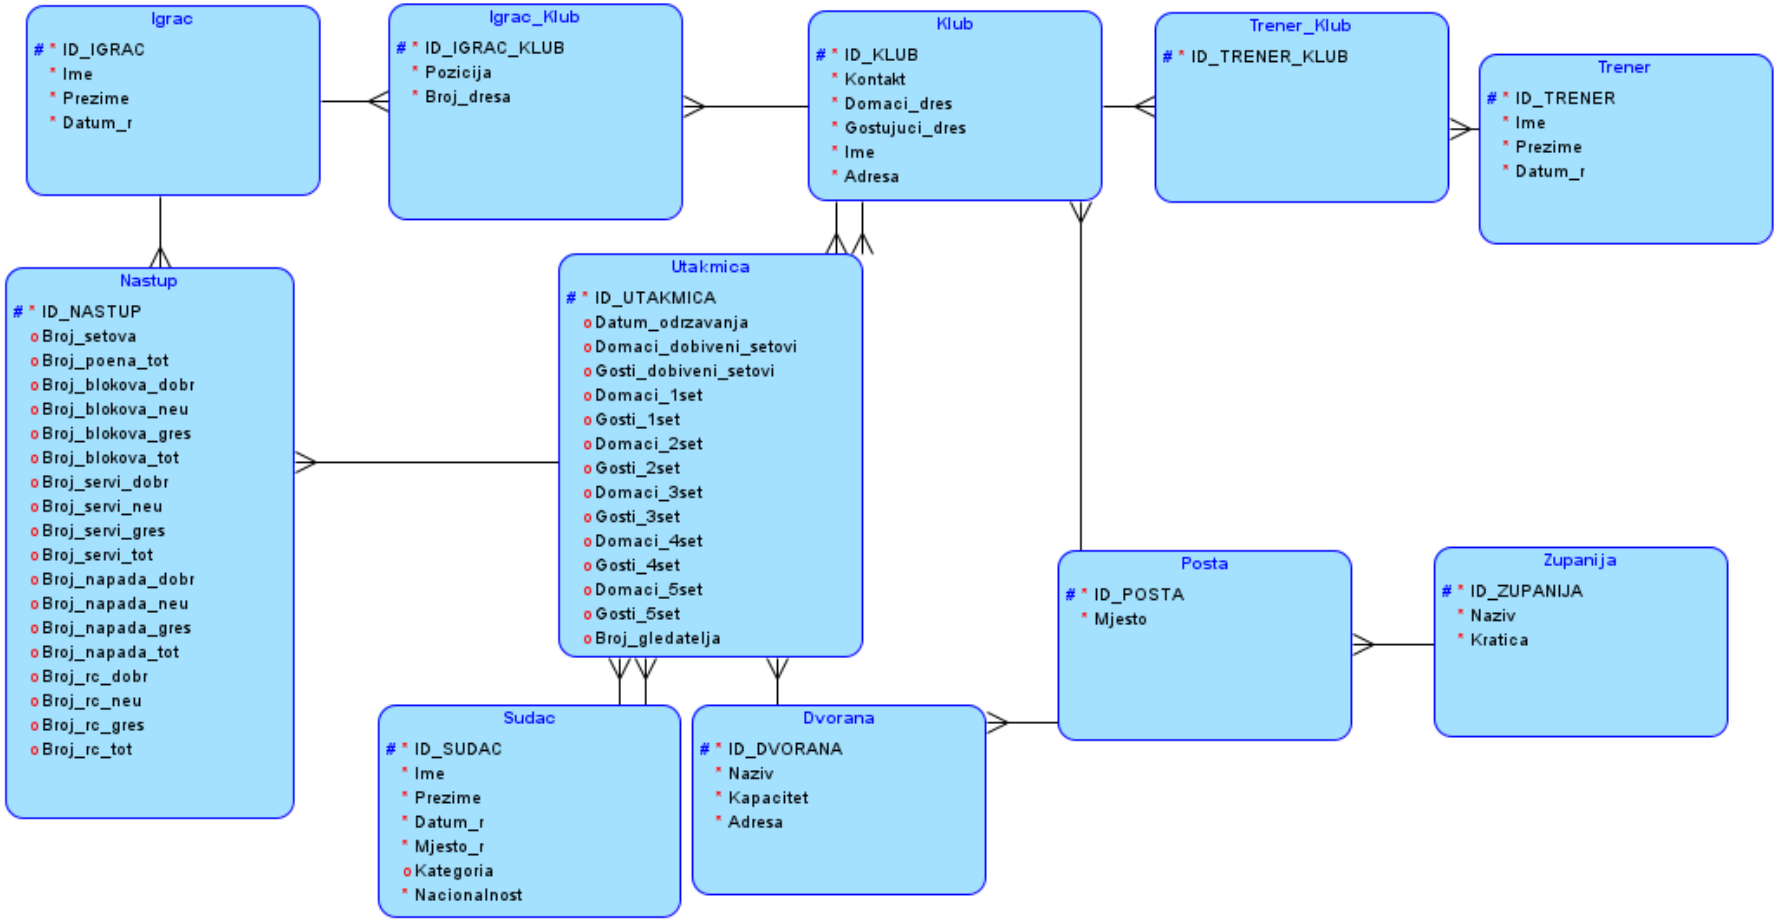
4.1. Konceptualni model



Slika 1: Konceptualni model

4.2. Logički Model

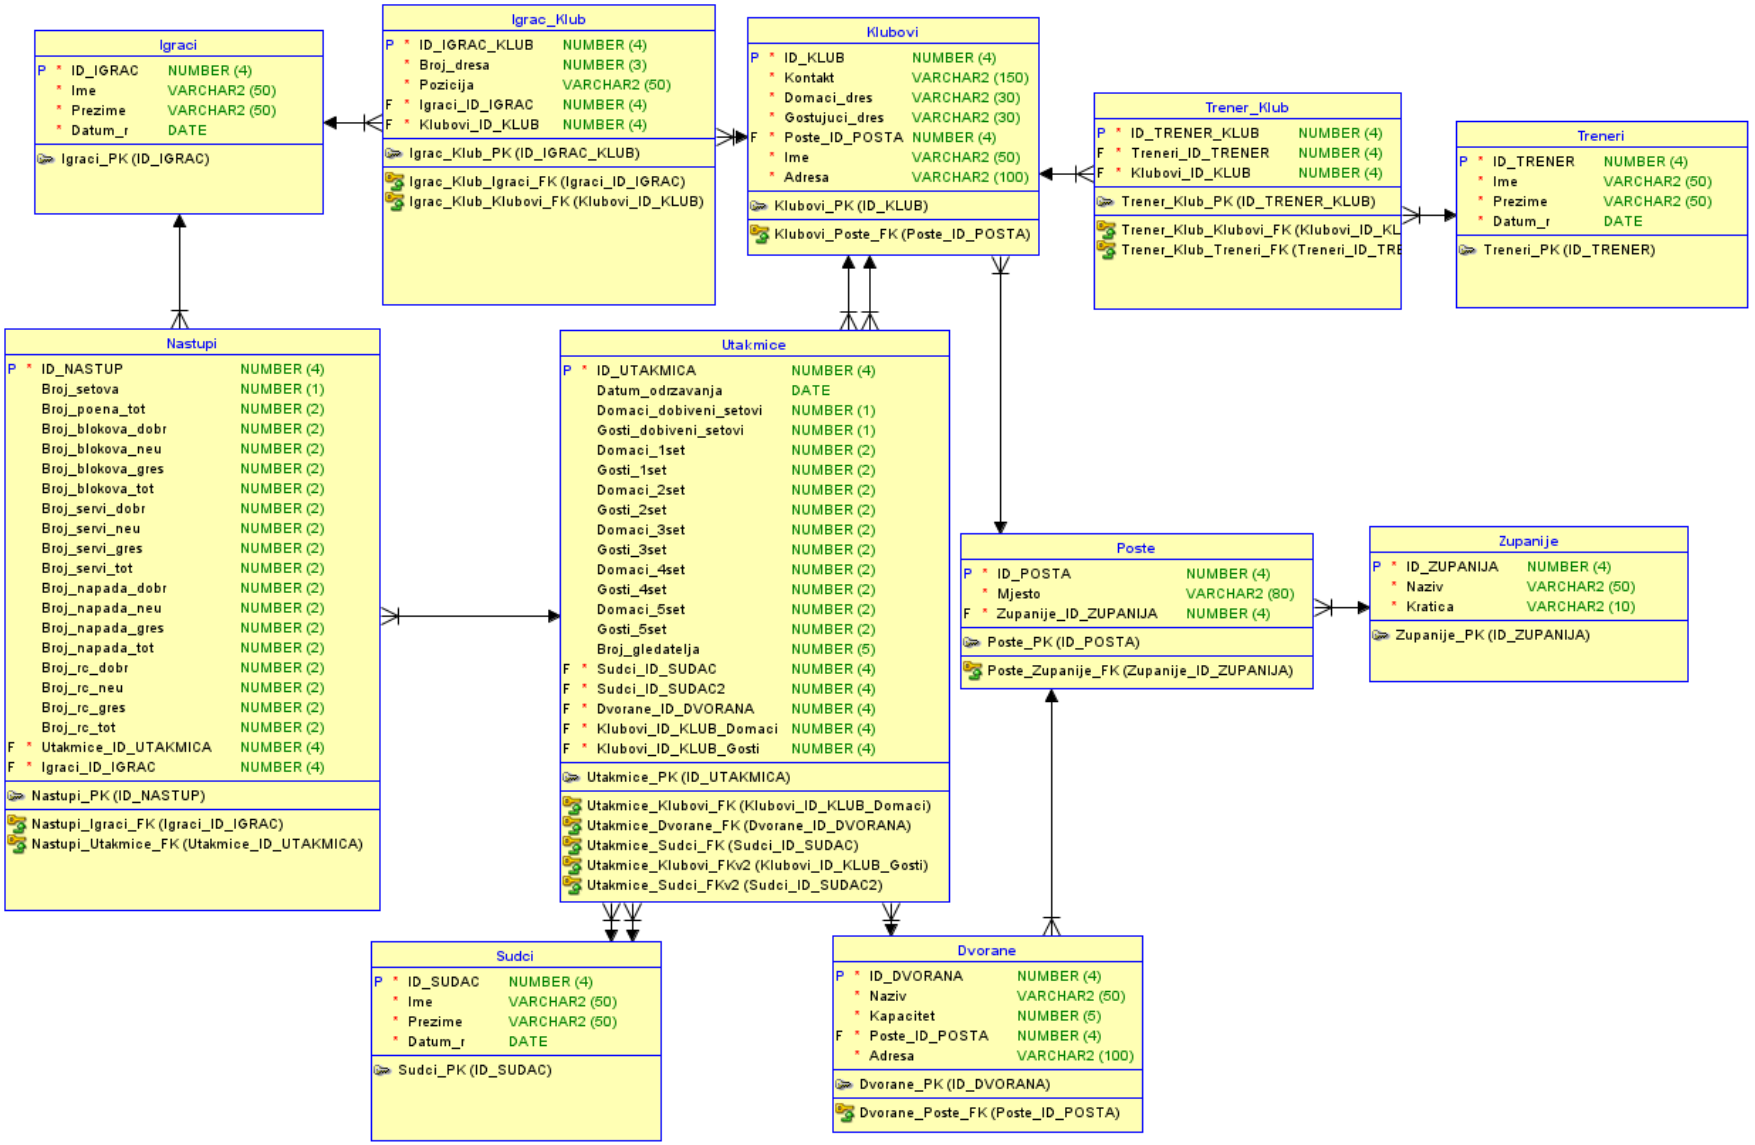
Logički model predstavlja strukturiran prikaz entiteta baze podataka koji su povezani određenim relacijama. U tablicama koje predstavljaju entitete vidljivi su svi korišteni atributi, primarni i/ili kompozitni ključevi, dok strani ključevi nisu eksplicitno prikazani u ovoj fazi modeliranja.



Slika 2: Logički model

4.3. Relacijski Model

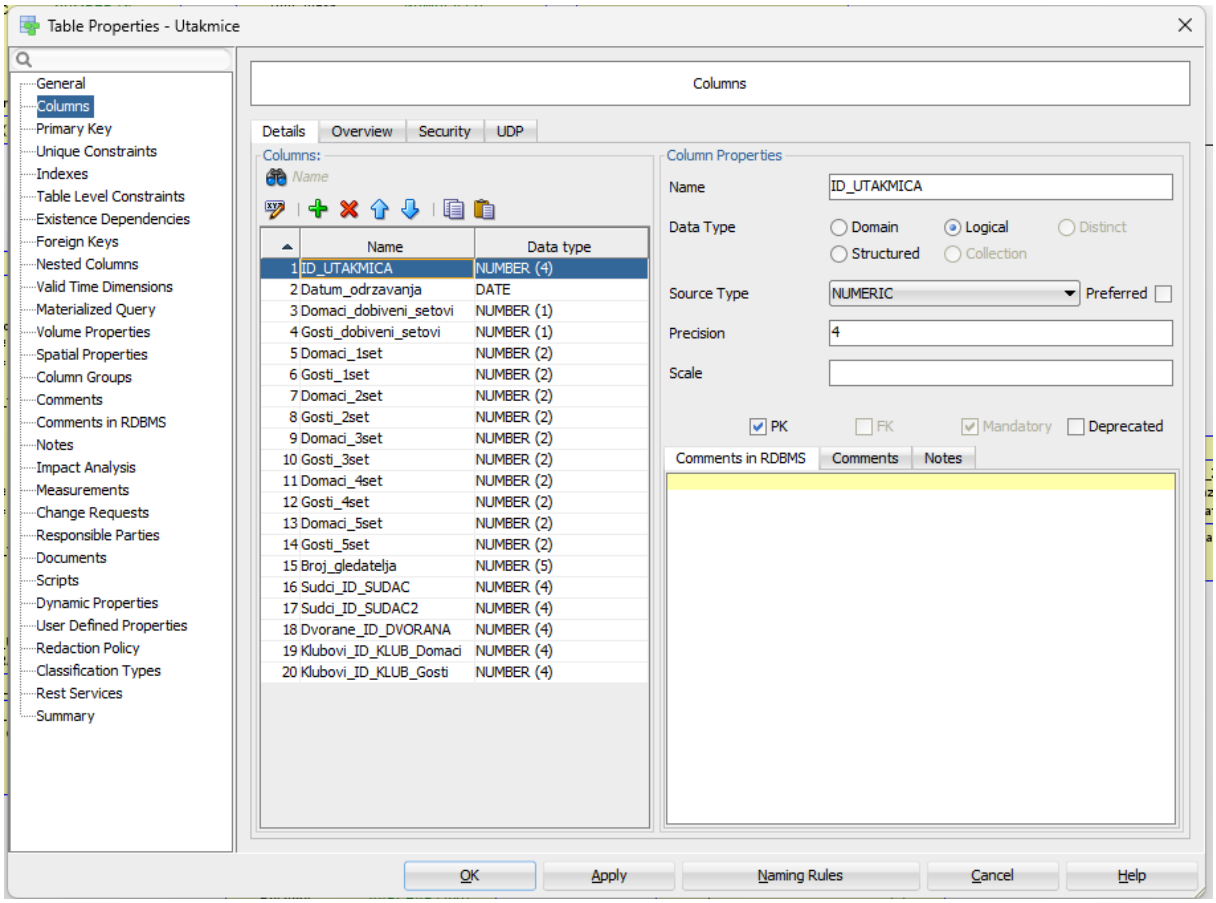
Nakon završenog logičkog modela generiramo i uređujemo relacijski model baze podataka koji pruža detaljniji prikaz strukture tablica. Iz ovog modela, osim entiteta, relacija i atributa, možemo vidjeti i tipove podataka, strane ključeve u svim tablicama, kao i ograničenja pojedinih atributa. Također, ukoliko je neki podatak unique (jedinstven), bit će označen odgovarajućom oznakom.



Slika 3: Relacijski model

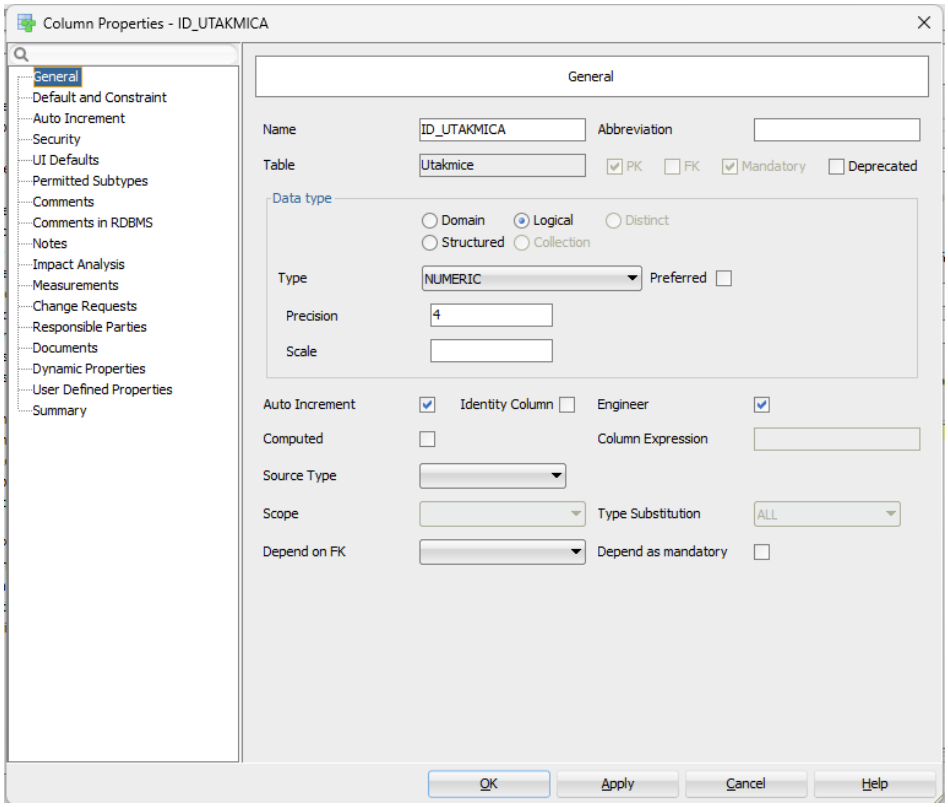
4.4. Generacija DDL-a

Nakon izrade logičkog i relacijskog modela trebamo napraviti bazu. Za to nam je potreban DDL kojeg generiramo iz SQL Datamodeler-u kojega ćemo izvršiti u SQL Developeru da napravimo tu bazu na serveru. Tada ćemo moći unositi podatke i izvršavati upite. No prije generiranja DDL-a moramo pripaziti da u Oracle-u nema ugrađenog tipa podataka za primarne ključeve pa moramo definirati svim primarnim ključevima sekvencu (sequence) i okidač (triger).
Kako bi postavili sekvencu i okidač moramo prvo dvoklik na entitet kako bi ušli u Table Properties tog entiteta.



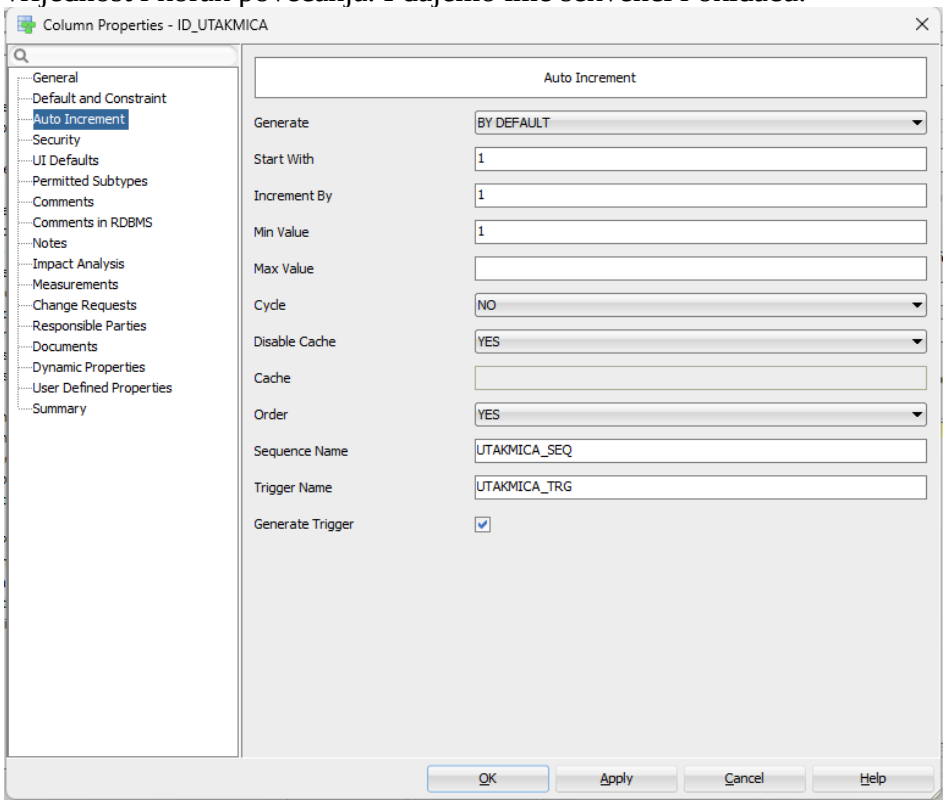
Slika 4: Table Properties

Nakon što smo u Table Properties meniju moramo napraviti dvoklik na atribut koji smo odredili kao primarni ključ pa na General izborniku označiti polje Auto Increment.



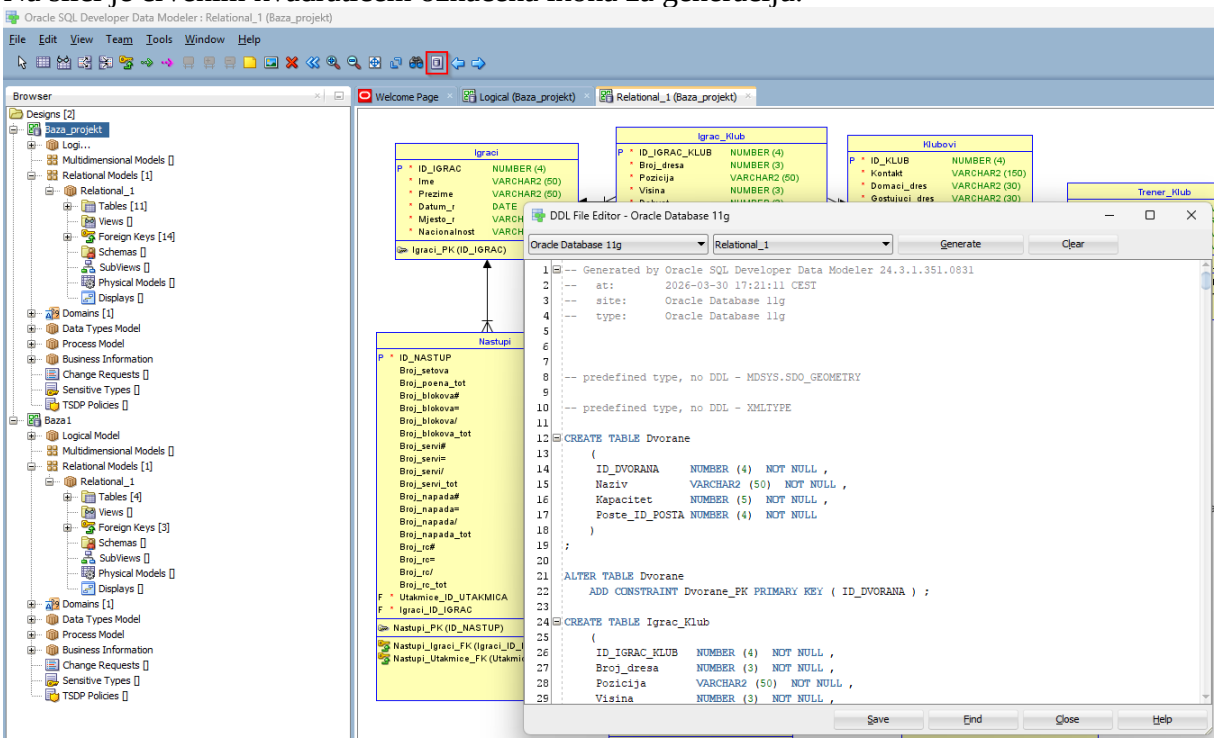
Slika 5: Column Properties, General - označavamo Auto Increment

Na kraju moramo ići pod polje Auto Increment i tamo dajemo početnu vrijednost, minimalnu vrijednost i korak povećanja. I dajemo ime sekvenci i okidaču.



Slika 6: Uređivanje Auto Increment stranice

Nakon što to odradimo možemo generirati DDL moramo pretisnuti ikonu za generiaciju i pretisnuti next na popup meniju i onda nam se otvara novi prozor s DDL-omm.
Na slici je crvenim kvadratičem označena ikona za generaciju.

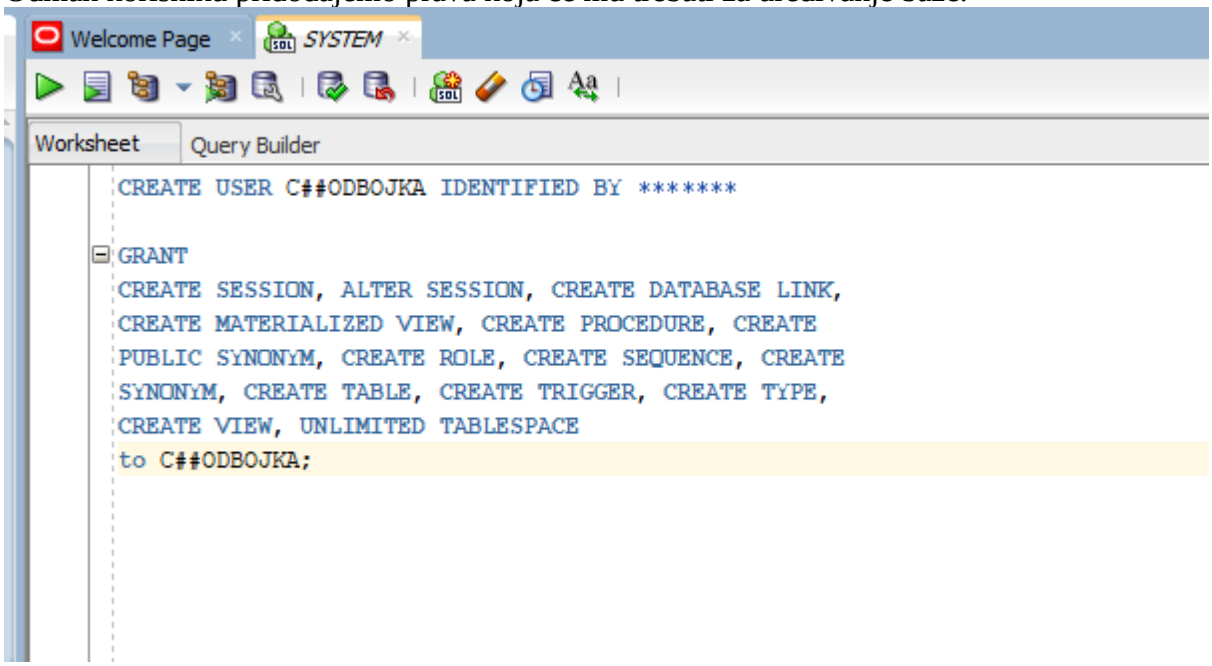


Slika 7: Generacija DDL fila

5. Izrada baze u SQL developeru

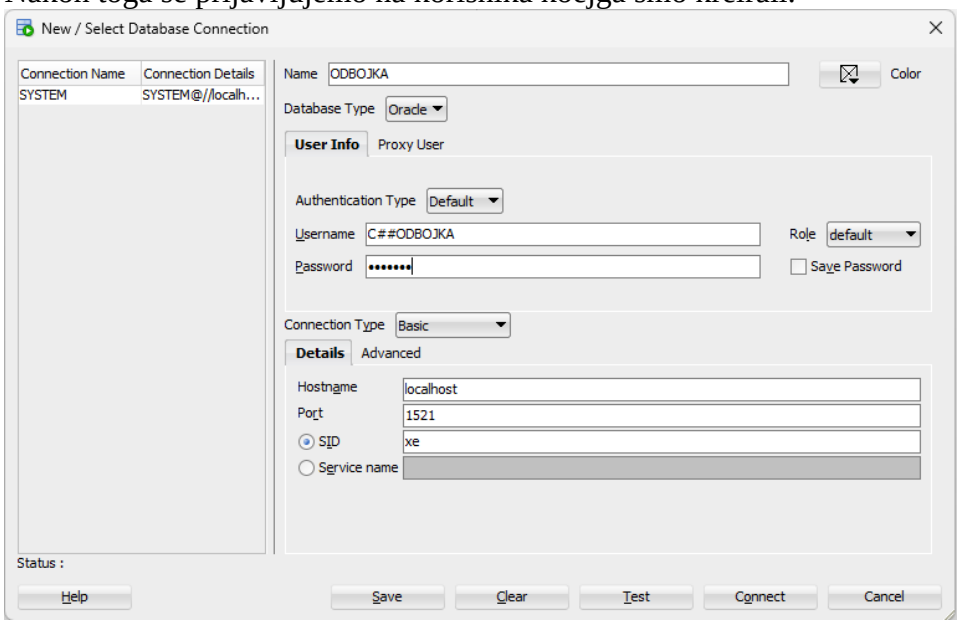
5.1. Izrada korisnika i dodjela prava

Ulazimo u System administrator stvaramo novog korisnika (Zove se C##ODBOJKA jer se u novijom verzijama developera 12c i novije costom usernamovi moraju oznaciti s C##)
Odmah korisniku pridodajemo prava koja će mu trebati za uređivanje baze.



5.2. Izrada veze na novog korisnika

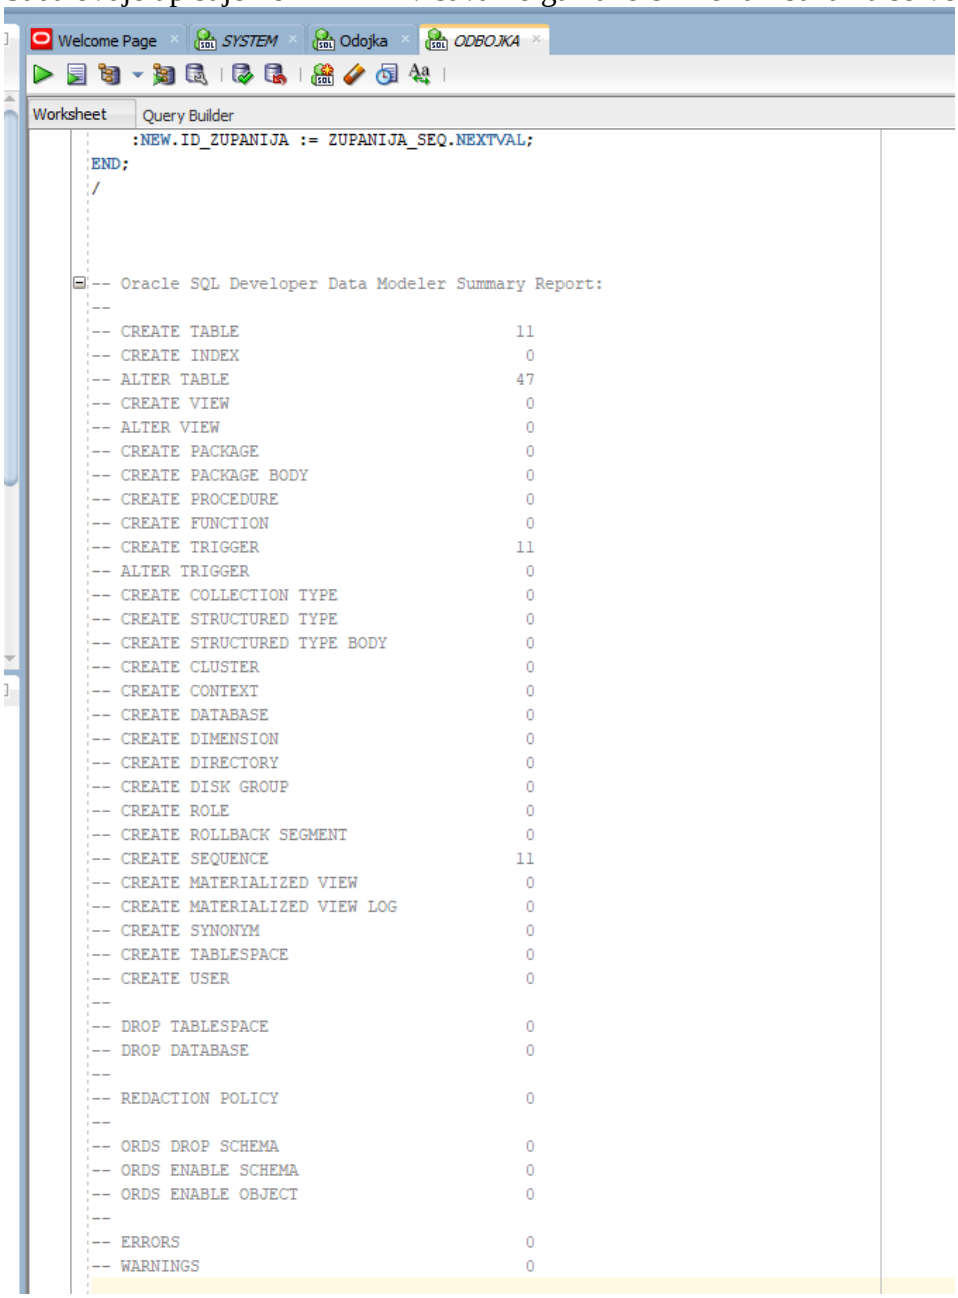
Nakon toga se prijavljujemo na korisnika koejga smo kreirali.



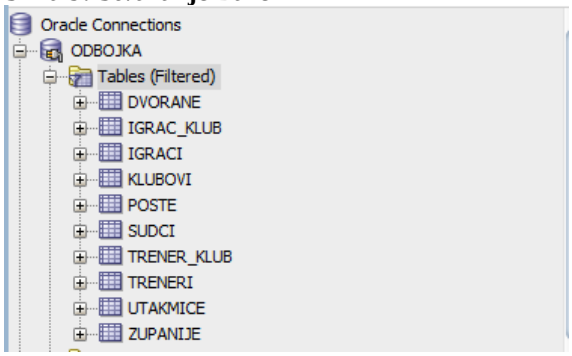
Slika 8: Prijava na našeg korisnika

5.3. Izvršavanje DDL-a

Sada ovdje upisujemo DDL i izvršavamo ga kako bi kreirali bazu na serveru.



Slika 9: Stvaranje Baze

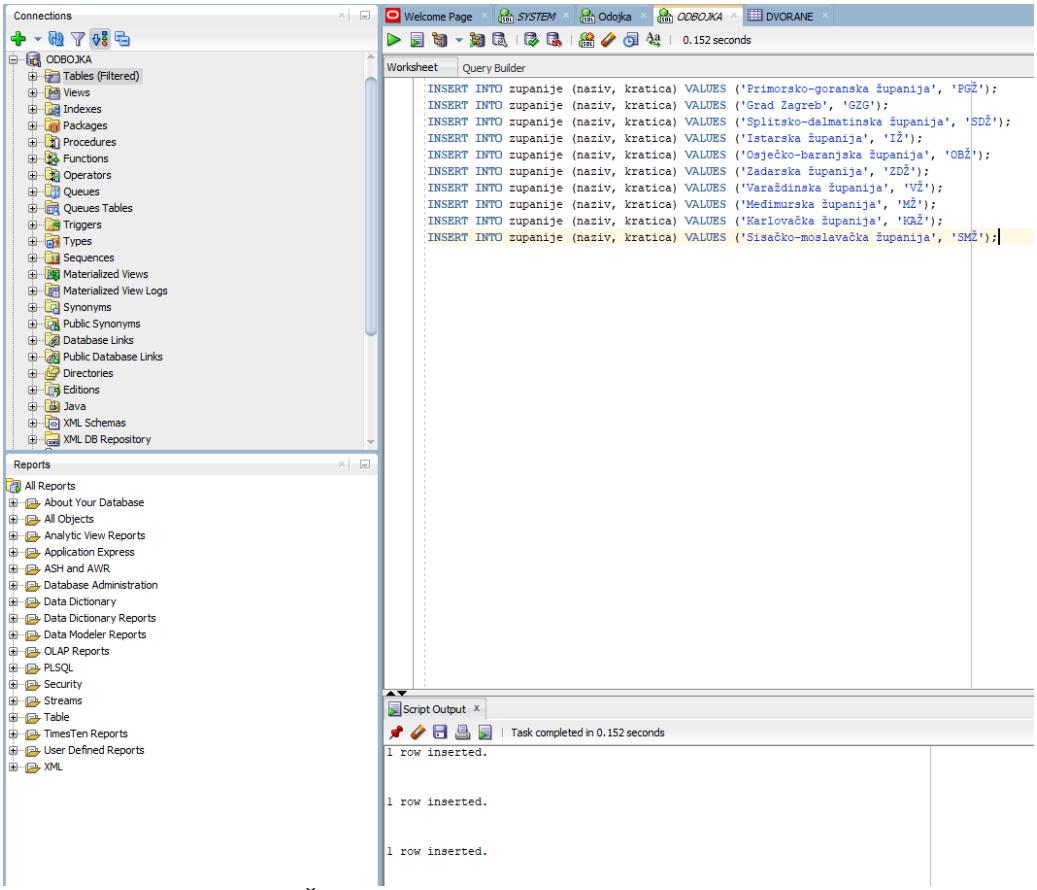


Slika 10: Stvorene tablice

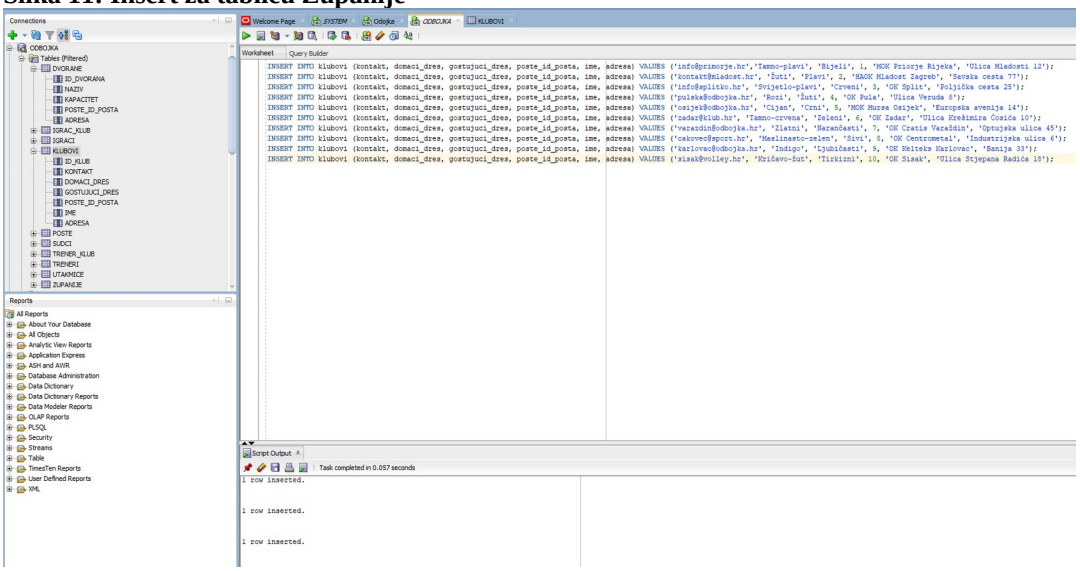
6. Upiti

6.1. Insert

Ovaj upit nam služi za unos podataka u bazu. Prvo moramo unijeti podatke u bate koje nemaju strane ključeve pa kasnije tek unosio podatke u baze s stranim ključevima kada odredimo vrijednosti tih stranih ključeva. Na kraju unosa kada smo potvrdili da smo sve dobro unijeli pišemo naredbu commit;. Primjer unosa možete vidjeti na slijedećim slikama:



Slika 11: Insert za tablicu Županije



Slika 12: Primjer inserta s stranim ključevima

6.2. Update

Update upit koristimo kada trebamo promijeniti neku vrijednost u tablici. Na primjer unešen je krivi kapacitet dvorane, možemo ga ovako ispraviti:

```
select * from dvorane;
```

Script Output | Query Result

SQL | All Rows Fetched: 10 in 0.005 seconds

	ID_DVORANA	NAZIV	KAPACITET	POSTE_ID_POSTA	ADRESA
4	4	Sportska dvorana Pula	2500	4	Ulica Rase 15
5	5	Gradska dvorana Osijek	4000	5	Kardinala Stepinca 1
6	6	Krešimir Ćosić Arena	6000	6	Majstora Radovana 11
7	7	Arena Varaždin	3500	7	Braće Radića 1
8	8	Dvorana Čakovec	2000	8	Športska ulica 9
9	9	Mala dvorana Karlovac	1500	9	Banjavčićeva 1
10	10	SC Sisak	2000	10	Sisak 25

Slika 13: Krivo unesen kapacitet za SC Sisku

Welcome Page | SYSTEM | ODSJEKA | DVORANE

Worksheet | Query Builder

```
update dvorane
set kapacitet=3000
where id_dvorana=10;

SELECT * FROM dvorane;
```

Script Output | Query Result

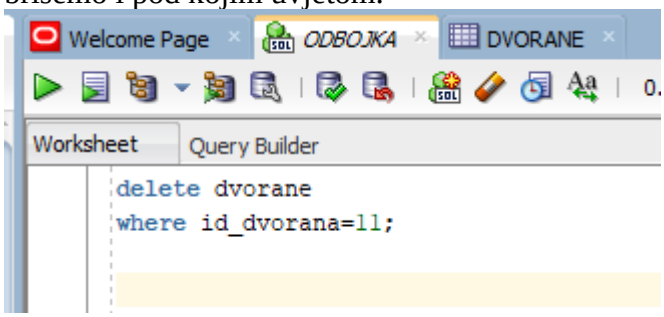
SQL | All Rows Fetched: 10 in 0.006 seconds

	ID_DVORANA	NAZIV	KAPACITET	POSTE_ID_POSTA	ADRESA
4	4	Sportska dvorana Pula	2500	4	Ulica Rase 15
5	5	Gradska dvorana Osijek	4000	5	Kardinala Stepinca 1
6	6	Krešimir Ćosić Arena	6000	6	Majstora Radovana 11
7	7	Arena Varaždin	3500	7	Braće Radića 1
8	8	Dvorana Čakovec	2000	8	Športska ulica 9
9	9	Mala dvorana Karlovac	1500	9	Banjavčićeva 1
10	10	SC Sisak	3000	10	Sisak 25

Slika 14: Korištenje Update upita za ispravljanje greške

6.3. Delete

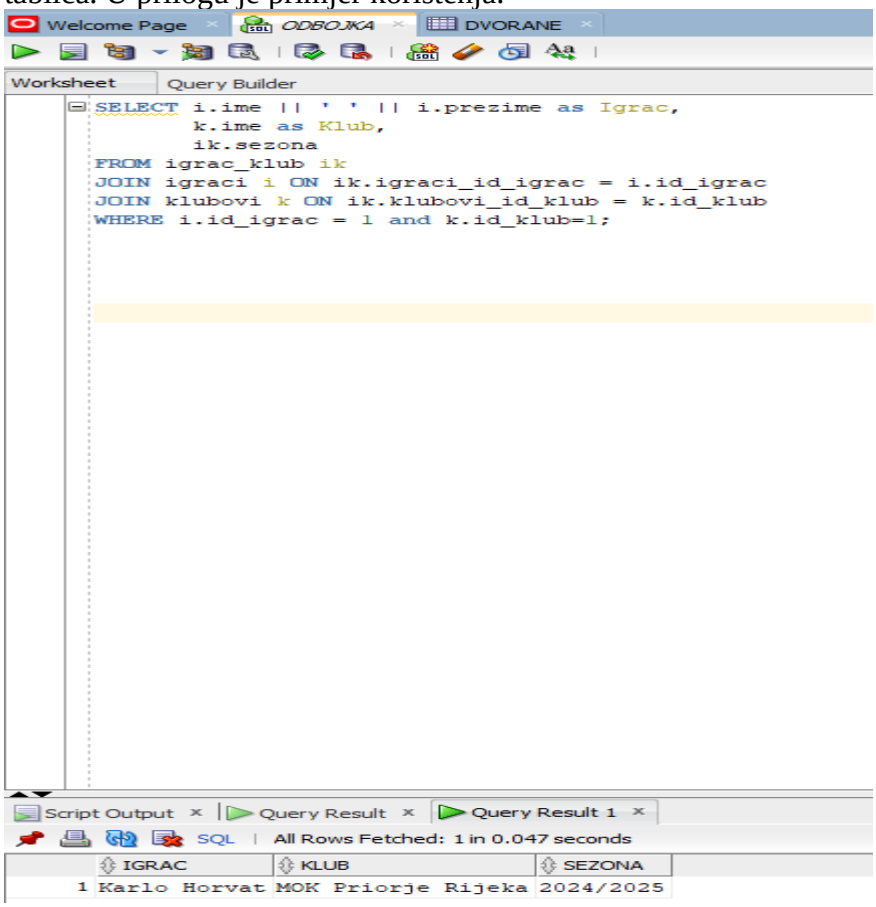
Delete upit koristimo kada trebamo pobrisati podatke u tablicama. Odredujemo iz koje tablice brisemo i pod kojim uvjetom.



Slika 15: Primjer brisanja dvorane s id-em od 11

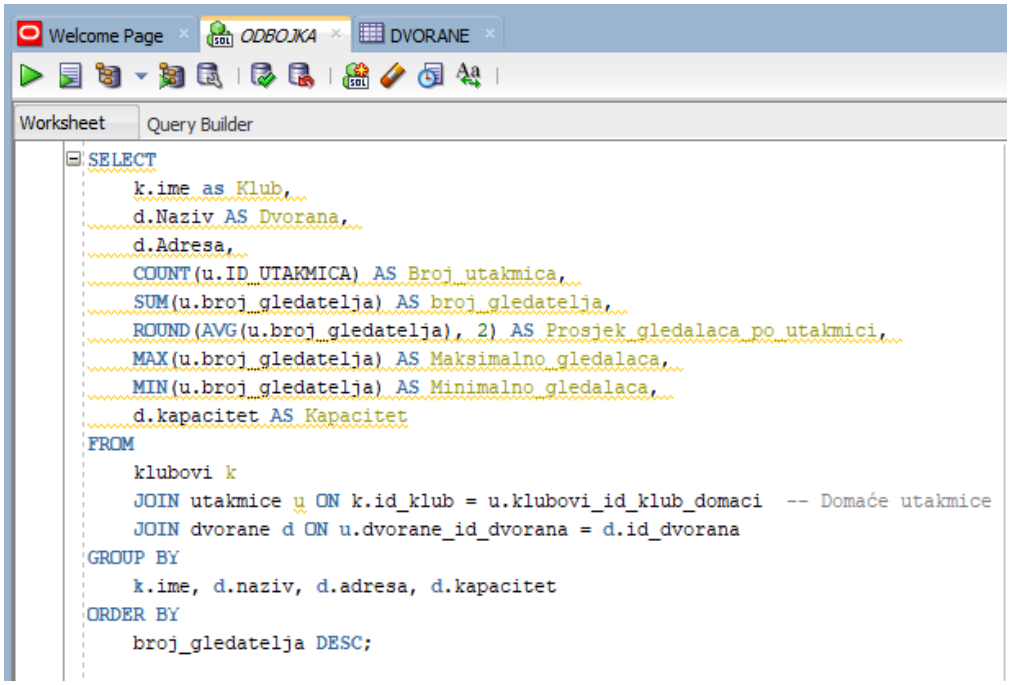
6.4. Select

Select upit je vrsta upita koju koristimo kada trebamo prikazati podatke iz jedne ili više tablica. U prilogu je primjer korištenja.

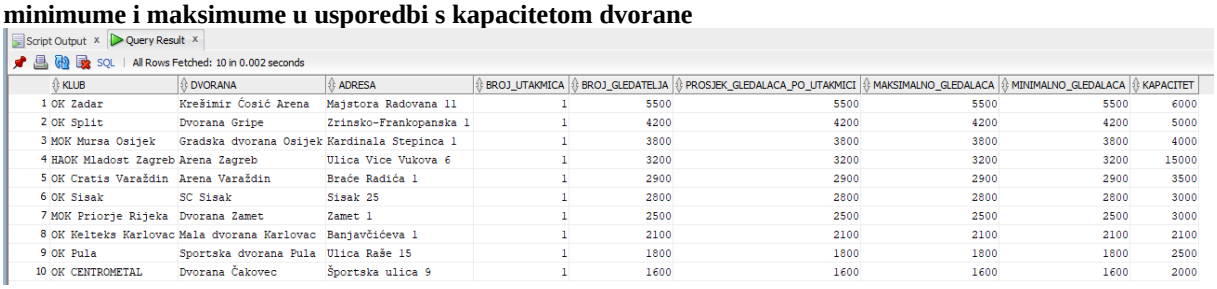


Slika 16: Pretražujemo igrača s id 1 i da je u klubu s id 1

7. Zadaci



Slika 17: Upit gdje gledamo koji je najgledaniji klub koliki njim je prosjek gledatelja po utakmici i minimume i maksimume u usporedbi s kapacitetom dvorane



	KLUB	DVORANA	ADRESA	BROJ_UTAKMICA	BROJ_GLEDATELJA	PROSJEK_GLEDALACA_PO_UTAKMICI	MAKSIMALNO_GLEDALACA	MINIMALNO_GLEDALACA	KAPACITET
1	OK Zadar	Krešimir Ćosić Arena	Majstora Radovana 11	1	5500	5500	5500	5500	6000
2	OK Split	Dvorana Gripe	Zrinsko-Frankopanska 1	1	4200	4200	4200	4200	5000
3	MOK Mursa Osijek	Gradska dvorana Osijek	Kardinala Stepinca 1	1	3800	3800	3800	3800	4000
4	HAOK Mladost Zagreb	Arena Zagreb	Ulica Vice Vukova 6	1	3200	3200	3200	3200	15000
5	OK Cratis Varaždin	Arena Varaždin	Braće Radića 1	1	2900	2900	2900	2900	3500
6	OK Sisak	SC Sisak	Sisak 25	1	2800	2800	2800	2800	3000
7	MOK Prirje Rijeka	Dvorana Zamet	Zamet 1	1	2500	2500	2500	2500	3000
8	OK Kelteks Karlovac	Mala dvorana Karlovac	Banjavčićeva 1	1	2100	2100	2100	2100	2100
9	OK Pula	Sportska dvorana Pula	Ulica Raše 15	1	1800	1800	1800	1800	2500
10	OK CENTROMETAL	Dvorana Čakovec	Športska ulica 9	1	1600	1600	1600	1600	2000

Slika 18: Rezultat upita sa slike 17

```sql
SELECT
    i.ime || ' ' || i.prezime as Igrac,
    ik.pozicija,
    COUNT(DISTINCT i.id_igrac) AS Broj_igraca,
    COUNT(DISTINCT n.utakmice_id_utakmica) AS Ukupno_nastupa,
    ROUND(AVG(n.broj_napada_dobr), 2) AS Prosjek_uspjesnih_napada,
    ROUND(AVG(n.broj_blokova_dobr), 2) AS Prosjek_blokova,
    ROUND(AVG(n.broj_servi_dobr), 2) AS Broj_dobrih_servi,
    ROUND(AVG(n.broj_rc_dobr), 2) AS Prosjek_spasavanja
FROM
    igraci i
    inner JOIN nastupi n ON i.id_igrac = n.igraci_id_igrac
    inner JOIN igrac_klub ik ON i.id_igrac = ik.igraci_id_igrac
GROUP BY
    ik.pozicija, i.ime, i.prezime
ORDER BY
    Broj_igraca DESC;
```

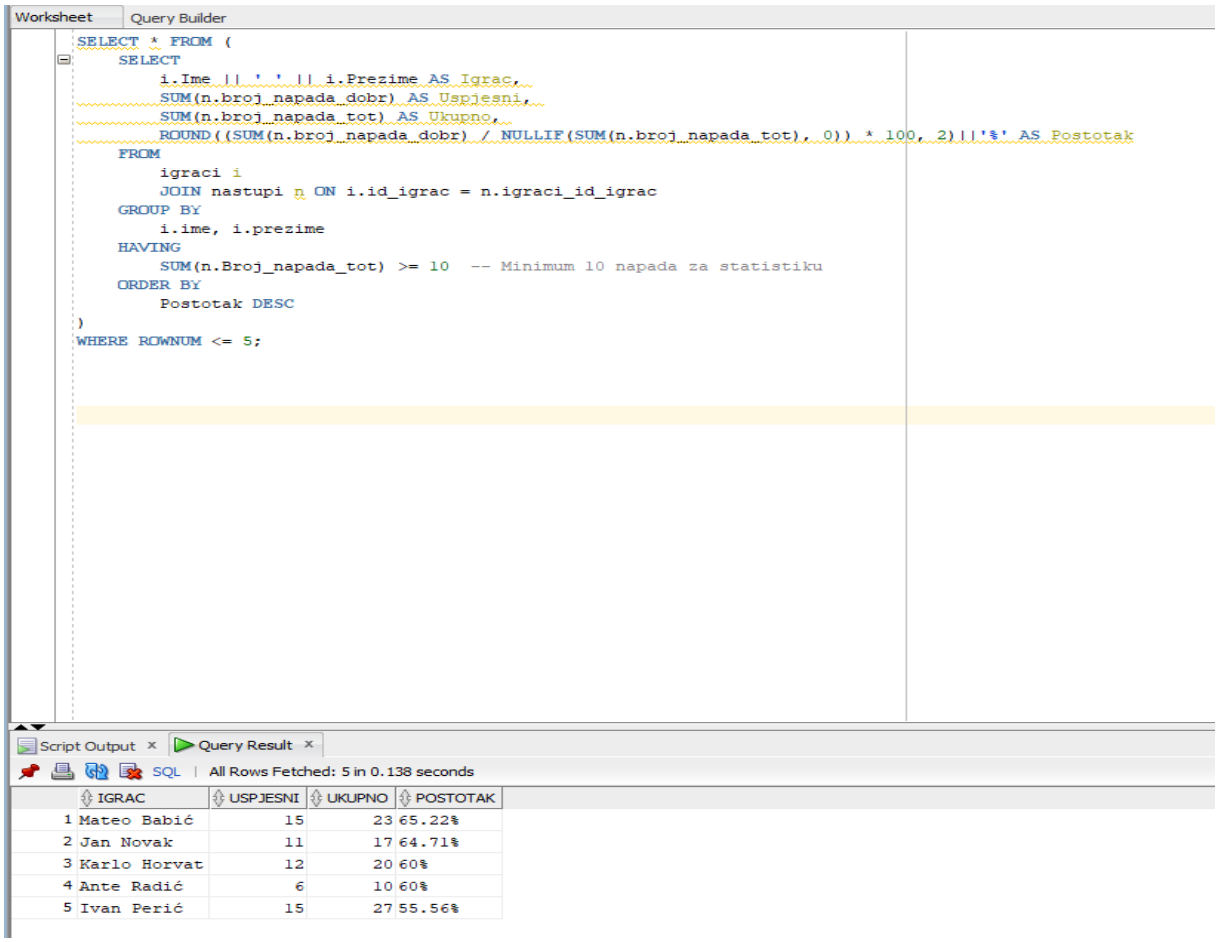
Slika 19: Usporedba igrača po pozicijama

Query Result

SQL | All Rows Fetched: 8 in 0.03 seconds

	IGRAC	POZICIJA	BROJ_IGRACA	UKUPNO_NASTUPA	PROSJEK_USPJESNIH_NAPADA	PROSJEK_BLOKOVA	BROJ_DOBRIH_SERVI	PROSJEK_SPASAVANJA
1	Karlo Horvat	Dizac	1	1	12	2	1	10
2	Ivan Perić	Korektor	1	1	15	4	3	12
3	Luka Marić	Srednji Bloker	1	1	5	5	0	8
4	Marco Rossi	Libero	1	1	5	0	0	5
5	Ante Radić	Dizac	1	1	6	1	1	20
6	Josip Kovačić	Korektor	1	1	19	6	5	11
7	Jan Novak	Srednji Bloker	1	1	11	2	1	9
8	Filip Jurić	Libero	1	1	18	3	4	14

Slika 20: Rezultat prijašnjih upita



Slika 21: Upit gdje izvlačimo 5 igrača s najboljim postotkom napada

```sql
WITH Klubske_utakmice AS (
    SELECT
        k.ID_KLUB,
        k.ime,
        u.ID_UTAKMICA,
        u.Datum_odrzavanja,
        CASE
            WHEN (u.klubovi_id_klub_domaci = k.id_klub AND u.domaci_dobiveni_setovi > u.gosti_dobiveni_setovi) OR
                 (u.klubovi_id_klub_gosti = k.id_klub AND u.gosti_dobiveni_setovi > u.domaci_dobiveni_setovi)
            THEN 'Pobjeda'
            ELSE 'Poraz'
        END AS Rezultat,
        CASE
            WHEN u.klubovi_id_klub_domaci = k.id_klub THEN u.domaci_dobiveni_setovi
            ELSE u.gosti_dobiveni_setovi
        END AS Dobiveni_setovi,
        CASE
            WHEN u.klubovi_id_klub_domaci = k.id_klub THEN u.gosti_dobiveni_setovi
            ELSE u.domaci_dobiveni_setovi
        END AS Izgubljeni_setovi,
        ROW_NUMBER() OVER (PARTITION BY k.id_klub ORDER BY u.datum_odrzavanja DESC) AS Rn
    FROM
        klubovi k
        JOIN utakmice u ON k.id_klub = u.klubovi_id_klub_domaci OR k.id_klub = u.klubovi_id_klub_gosti
)
SELECT
    ime,
    COUNT(*) AS Odigrano_utakmica,
    SUM(CASE WHEN Rezultat = 'Pobjeda' THEN 1 ELSE 0 END) AS Pobjede,
    SUM(CASE WHEN Rezultat = 'Poraz' THEN 1 ELSE 0 END) AS Porazi,
    ROUND((SUM(CASE WHEN Rezultat = 'Pobjeda' THEN 1 ELSE 0 END) / NULLIF(COUNT(*), 0)) * 100, 2) AS Postotak_pobjeda,
    SUM(Dobiveni_setovi) AS Ukupno_dobivenih_setova,
    SUM(Izgubljeni_setovi) AS Ukupno_izgubljenih_setova,
    SUM(Dobiveni_setovi) - SUM(Izgubljeni_setovi) AS Set_razlika,
    LISTAGG(
        CASE WHEN Rezultat = 'Pobjeda' THEN 'P' ELSE 'I' END,
        '-'
    ) WITHIN GROUP (ORDER BY Datum_odrzavanja DESC) AS Forma_niz
FROM
    Klubske_utakmice
WHERE
    Rn <= 5
GROUP BY
    ID_KLUB, ime
ORDER BY
    Postotak_pobjeda DESC, Set_razlika DESC;
```

Slika 22: Upit za gledanje rezultata zadnjih 5 utakmica gledamo broj dobivenih broj izgubljenih set razliku i pratimo koje su pobijedili i koje izgubili

	IME	ODIGRANO_UTAKMICA	POBJEDE	PORAZI	POSTOTAK_POBJEDA	UKUPNO_DOBIVENIH_SETOVA	UKUPNO_IZGUBLJENIH_SETOVA	SET_RAZLIKA	FORMA_NIZ
1	MOK Mursa Osijek	2	2	0	100	6	2	4	P-P
2	OK Cratis Varaždin	2	2	0	100	6	2	4	P-P
3	OK Sisak	2	2	0	100	6	2	4	P-P
4	OK Split	2	1	1	50	5	3	2	P-I
5	MOK Priorje Rijeka	2	1	1	50	4	4	0	I-P
6	HAOK Mladost Zagreb	2	1	1	50	4	5	-1	P-I
7	OK CENTROMETAL	2	1	1	50	3	5	-2	P-I
8	OK Zadar	2	0	2	0	3	6	-3	I-I
9	OK Kelteks Karlovac	2	0	2	0	3	6	-3	I-I
10	OK Pula	2	0	2	0	1	6	-5	I-I

Slika 23: Rezultat upita sa slike 20